



Travail de recherche MIDL 2

CROS Hélène & SALLET Eloïse

Travail Encadré par E.CLAEYS
Janvier - Juin 2026

Table des matières

1	Introduction	2
2	Compréhension des Données et Mise en Contexte	3
3	Approche selon différents modèles	4
3.1	Gradient Boosting Deux Modèles : Coût et Fréquence	4
3.2	Gradient Boosting Modèle Unique : Tweedie	6
3.3	Réseau de neurones	7
4	Augmentation des données par réseau génératif	8
4.1	Introduction aux CTGAN	8
4.2	Entraînement et Résultats des Modèles sur ces Données	8
5	Équité du Modèle : Disparate Impact	10
5.1	Définition et cadre théorique	10
5.2	Adaptation au contexte de régression	11
5.3	Choix de la variable sensible	11
5.4	Résultats	12
5.5	Interprétation	12
6	Conclusion	12

1 Introduction

Ce Travail Encadré de Recherche porte sur le challenge AssurPrime organisé par Crédit Agricole Assurances [1]. L'objectif est d'identifier le modèle le plus performant pour prédire la prime pure liée au risque incendie au sein du contrat multirisque agricole.

La variable cible finale, appelée charge, est calculée comme le produit de la fréquence prédite, du coût moyen estimé et du nombre d'années depuis la souscription du contrat. Le jeu de données comprend plus de 300 variables couvrant des dimensions géographiques, météorologiques et des spécificités techniques propres aux contrats.

Nous nous sommes donc basées sur ce challenge car nous avons accès à une grande quantité de données pour tester différents modèles. De plus, nous avons pu nous évaluer directement selon notre RMSE calculée par l'organisateur et nous plaçant dans un classement. Nous avons testé nos hypothèses dans un notebook disponible sur GitHub [2].

Dans ce rapport, nous commencerons par analyser les données disponibles afin de comprendre leur structure et les défis qu'elles posent. Nous présenterons ensuite nos différentes approches de modélisation : le Gradient Boosting avec décomposition fréquence-coût, le modèle Tweedie unifié, puis les réseaux de neurones denses. Nous explorerons également une stratégie d'augmentation des données par réseau génératif (CTGAN), visant à pallier le fort déséquilibre des sinistres. Enfin, nous étudierons l'équité de notre meilleur modèle à travers le prisme du disparate impact, afin d'évaluer si certains groupes d'assurés sont systématiquement défavorisés par nos prédictions.

2 Compréhension des Données et Mise en Contexte

Une première étape essentielle à notre projet est de comprendre les données que nous avons. Savoir quels fichiers sont fournis, étudier leur contenu, réfléchir à comment les utiliser et surtout savoir quelles données nous devons retourner.

Comme dans la plupart des challenges de ce type, trois fichiers principaux sont donnés : `x_train`, `y_train` et `x_test`. Nous avons de plus des fichiers complémentaires qui comprennent des exemples de soumission, l'explication des variables et un exemple de notebook.

Analyse des variables explicatives (`x_train` et `x_test`)

Le fichier `x_train` contient l'ensemble des caractéristiques associées à chaque contrat pour l'entraînement des modèles. Il comporte 383 610 lignes et 374 colonnes. Le fichier `x_test`, quant à lui, dispose des mêmes 374 colonnes explicatives mais sert exclusivement à l'évaluation finale sur la plateforme du challenge.

Compte tenu de la dimension de `x_train`, un affichage brut de ses premières lignes est impossible à intégrer de manière lisible dans ce rapport. Cependant, l'analyse de sa structure nous permet de regrouper ces 374 variables en plusieurs grandes thématiques techniques et environnementales :

Catégorie de variables	Exemples de blocs de colonnes	Description du contenu
Informations Contrat & Client	ID, ANNEE_ASSURANCE, ANCIENNETE	Identification, durée et antécédents.
Activité Exploitation	ACTIVIT, VOCATION, TYPERS	Type de profil agricole ou professionnel.
Bâtiments & Surfaces	SURFACE1 à 21, NBBAT1 à 14, TYPBAT	Caractéristiques physiques des infrastructures.
Garanties & Capitaux	KAPITAL1 à 43, FRCH1, INDEM1	Limites financières, franchises et couvertures.
Données Démographiques	PROPORTION_, MEN_PAUVMEN, INSEE	Données socio-économiques locales de la commune.
Topographie & Risques	ALTITUDE_, DISTANCE_, RISK1 à 13	Environs géographiques et zones à risque.
Variables Climatiques (Météo)	ANBJTX_, ARR_VOR_, ANBJFF_	Températures, vents, gels et pluviométrie de la zone.

On relève également la présence notable de valeurs manquantes (notées `NaN` dans nos structures de données, comme pour certaines variables de distances ou de surfaces), ainsi que de nombreuses variables catégorielles textuelles ou codées sous forme d'intervalles (par exemple `05 - [1M - 1.5M]`). Un travail conséquent de pré-traitement, d'encodage et d'imputation sera donc indispensable avant l'intégration de ces matrices dans nos modèles de Gradient Boosting et nos réseaux de neurones.

Analyse de la variable cible (`y_train`)

Le fichier `y_train` contient la variable cible finale appelée `CHARGE`, ainsi que ses composantes directes permettant d'évaluer le risque incendie. Il compte 5 colonnes et 383 610 lignes. Voici les 5 premières lignes du fichier :

ID	FREQ	CM	ANNEE_ASSURANCE	CHARGE
1	0	0	1.000000	0
2	0	0	1.000000	0
3	0	0	0.402740	0
4	0	0	0.246575	0
5	0	0	0.838356	0

L'analyse de ce premier aperçu met en évidence le nombre important de zéros. En effet, sur les cinq premières lignes observées, les variables `FREQ` (fréquence de sinistre), `CM` (coût moyen) et `CHARGE` (le coût total) sont systématiquement nulles. Cette situation est tout à fait normale d'un point de vue métier car les incendies de bâtiments agricoles sont des événements graves mais heureusement très rares. La grande majorité des contrats de notre échantillon d'entraînement n'a donc subi aucun sinistre au cours de l'année d'observation.

Cette structure de données, dite « gonflée en zéros », représente un défi majeur pour la modélisation. Un modèle naïf qui prédirait toujours zéro obtiendrait une excellente précision globale en apparence, mais échouerait complètement à identifier les risques réels.

L'objectif final de ce projet est d'appliquer les relations apprises sur ce fichier `y_train` pour prédire la variable cible sur le jeu de test, afin de soumettre nos résultats sous la forme d'un fichier `y_test`. La

qualité de nos prédictions sera évaluée directement sur la plateforme Challenge Data selon la métrique de la RMSE (*Root Mean Squared Error*). Cette fonction de perte étant particulièrement sensible aux grandes erreurs, la détection correcte des rares sinistres à coût élevé (les fortes valeurs de **CHARGE**) sera la clé pour obtenir un bon score et progresser dans le classement du challenge.

3 Approche selon différents modèles

3.1 Gradient Boosting Deux Modèles : Coût et Fréquence

Notre première approche de modélisation s'appuie sur le framework LightGBM, une implémentation performante du gradient boosting particulièrement adaptée aux jeux de données tabulaires de grande dimension. Nous suivons ici la décomposition actuarielle classique de la prime pure [3] conseillée dans les règles du challenge, qui consiste à modéliser séparément la fréquence et le coût moyen des sinistres, puis à les recombinaison pour reconstituer la charge finale :

$$\text{CHARGE} = \text{FRÉQ} \times \text{CÔT} \times \text{ANNEE_ASSURANCE}$$

Avant l'entraînement, nous avons effectué un léger prétraitement des données. Nous avons converti les variables catégorielles textuelles en type `category`. Elles sont ainsi transmises directement à LightGBM, qui dispose d'un mécanisme natif de gestion de ce type de variables. De plus, nous avons exclu les colonnes `ID` et `ANNEE_ASSURANCE` des matrices d'entrée, car `ID` n'apporte rien à notre prédiction et `ANNEE_ASSURANCE` est utilisée uniquement comme exposant lors du calcul final de la charge.

Modèle fréquence (loi de Poisson)

Le premier modèle cible la variable `FREQ`, qui représente le nombre de sinistres observés. La loi de Poisson est naturellement adaptée à la modélisation de comptages d'événements rares, ce qui correspond bien à notre contexte. Les principaux hyperparamètres retenus selon la documentation LightGBM [4] sont les suivants :

Hyperparamètre	Valeur
<code>objective</code>	<code>poisson</code>
<code>learning_rate</code>	0.005
<code>num_leaves</code>	7
<code>min_data_in_leaf</code>	1000
<code>feature_fraction</code>	0.3
<code>lambda_l2</code>	10
<code>num_boost_round</code>	2000 (avec early stopping à 100 rounds)

L'ajustement de ces hyperparamètres répond à une stratégie de régularisation stricte, rendue indispensable par la rareté des sinistres incendies et le risque élevé de surapprentissage :

- `num_leaves` : Fixé à une valeur très basse (7), ce paramètre limite le nombre maximal de feuilles par arbre. Cela permet de forcer la création d'arbres très simples et peu profonds pour éviter que le modèle ne capture du bruit statistique.
- `lambda_l2` : Ce coefficient applique une régularisation L2 (Ridge) sur les poids des feuilles. Une valeur élevée (10) pénalise les prédictions trop extrêmes et lisse le comportement global du boosting.
- `min_data_in_leaf` : En imposant un minimum de 1 000 observations par feuille, on empêche LightGBM de créer des règles spécifiques basées sur une poignée de contrats seulement, ce qui est crucial pour un événement rare.
- `feature_fraction` : Fixé à 0.3, il indique que le modèle ne sélectionne de manière aléatoire que 30 % des 374 variables explicatives lors de la construction de chaque arbre. Ce mécanisme, inspiré des forêts aléatoires, décorrèle les arbres et renforce la robustesse globale.
- `learning_rate` & `num_boost_round` : Un taux d'apprentissage très faible (0.005) combiné à un grand nombre d'itérations garantit une descente de gradient progressive et stable.

Enfin, pour valider notre entraînement, le jeu de données initial a été séparé de façon classique : 80 % des données sont dédiées à l'apprentissage pur, tandis que les 20 % restants servent de jeu de validation

indépendant. Ce dernier permet de suivre l'évolution de la fonction de perte au fil des itérations et de déclencher l'*early stopping* (arrêt prématuré) si les performances sur le jeu de validation cessent de s'améliorer pendant 100 rounds consécutifs, figeant ainsi le modèle à son niveau de généralisation optimal.

Modèle coût moyen (loi Gamma)

Le second modèle cible la variable **CM**, qui représente le coût moyen conditionnel à l'occurrence d'un sinistre. Ce modèle n'est entraîné que sur le sous-ensemble des contrats pour lesquels un sinistre a effectivement eu lieu, c'est-à-dire les observations vérifiant simultanément $\text{FREQ} > 0$ et $\text{CM} > 0$. La loi Gamma est ici privilégiée car elle est définie sur les réels strictement positifs et possède une queue de distribution plus lourde que la loi normale, mieux adaptée aux coûts de sinistres qui peuvent être très élevés.

Hyperparamètre	Valeur
<code>objective</code>	gamma
<code>learning_rate</code>	0.005
<code>num_leaves</code>	12
<code>min_data_in_leaf</code>	30
<code>feature_fraction</code>	0.6
<code>lambda_l1</code>	0.1
<code>num_boost_round</code>	3000 (avec <i>early stopping</i> à 100 rounds)

- **num_leaves** : Augmenté à 12, il permet de construire des arbres légèrement plus profonds et complexes que pour la fréquence, ce qui s'avère nécessaire pour capturer la forte dispersion et la variabilité des montants de dommages.
- **min_data_in_leaf** : Réduit à 30, ce paramètre autorise la création de feuilles sur des groupes de contrats beaucoup plus petits. Cela permet au modèle de s'ajuster finement aux spécificités des sinistres coûteux sans être noyé par la masse.
- **feature_fraction** : Élevé à 0.6, il permet à LightGBM de piocher parmi 60 % des variables explicatives à chaque arbre. Offrir un espace de solutions plus riche aide à mieux identifier les interactions complexes entre les caractéristiques des bâtiments et la gravité de l'incendie.
- **lambda_l1** : Une régularisation L1 (Lasso) très légère (0.1) est introduite ici. Elle pousse le modèle à effectuer une sélection de variables en forçant le poids des caractéristiques redondantes ou inutiles à zéro.
- **learning_rate & num_boost_round** : On conserve un taux d'apprentissage très bas (0.005) mais avec un nombre maximal d'arbres plus important (3 000), garantissant une convergence ultra-précise guidée par l'évaluation continue de l'échantillon de validation (20 %) et son *early stopping* à 100 rounds.

Résultats

Les prédictions des deux modèles sont reconstituées en multipliant la fréquence prédite, le coût moyen prédit et l'exposition de chaque contrat. Un clipping est appliqué pour plafonner les valeurs aberrantes à 120% du maximum observé en entraînement, et les éventuelles valeurs manquantes sont remplacées par la charge moyenne.

Cette méthode nous a permis d'obtenir un score de 5600 sur la plateforme Challenge Data, ce qui nous place à la 63^e place du classement, à seulement 6 points du benchmark organisateur (5617) et à 6 points du premier (5594).

Ce résultat est encourageant à plusieurs titres : d'abord, il valide la pertinence de la décomposition fréquence-coût avec des distributions adaptées à chaque composante. Ensuite, l'écart très faible avec le meilleur score du classement suggère que l'approche est bien calibrée globalement, mais que les marges de progression résident probablement dans la détection des sinistres rares à coût très élevé, qui pèsent fortement sur la RMSE.

Ces observations motivent l'exploration d'approches alternatives, notamment un modèle unique reposant sur la loi de Tweedie, qui modélise directement la charge brute en combinant implicitement les deux composantes, ainsi que des architectures de réseaux de neurones capables de capturer des interactions non-linéaires plus complexes entre les variables.

3.2 Gradient Boosting Modèle Unique : Tweedie

Motivation et présentation de la loi de Tweedie

L'approche précédente, bien que performante, repose sur deux modèles distincts entraînés séparément. Cependant, cela peut causer un problème car les erreurs de chaque composante peuvent se propager et s'accumuler lors de la recombinaison finale. Une alternative naturelle consiste à modéliser directement la variable **CHARGE** en une seule étape, sans décomposition explicite fréquence-coût.

La loi de Tweedie [5, 6] constitue un cadre théorique particulièrement adapté à cet objectif. Il s'agit d'une famille de distributions exponentielles paramétrées par un indice $p \in \mathbb{R}$, qui englobe plusieurs lois classiques comme cas particuliers : la loi gaussienne ($p = 0$), la loi de Poisson ($p = 1$), la loi Gamma ($p = 2$) et la loi inverse gaussienne ($p = 3$). Pour $p \in (1, 2)$, la loi de Tweedie est définie sur $\mathbb{R}^+$ et place une masse de probabilité non nulle en zéro, tout en autorisant des valeurs strictement positives à queue lourde. Formellement, on peut écrire :

$$\mathbb{P}(Y = 0) > 0 \quad \text{et} \quad Y \mid Y > 0 \sim \text{Gamma}$$

Cette structure correspond exactement à la distribution de notre variable **CHARGE** car la grande majorité des contrats présente une charge nulle (absence de sinistre), tandis que les contrats sinistrés affichent des montants strictement positifs et très dispersés. La loi de Tweedie modélise donc implicitement la décomposition fréquence-coût sans nécessiter deux modèles distincts, ce qui simplifie le code et élimine les erreurs de propagation entre étapes.

Paramétrage du modèle

Le modèle est entraîné directement sur la variable **CHARGE** brute, sur l'ensemble des contrats (sinistrés ou non), en utilisant l'objectif **tweedie** de LightGBM. Le paramètre **tweedie_variance_power** contrôle la position dans la famille : une valeur proche de 1 rapproche le modèle d'un comportement poissonien (sensible à la fréquence), tandis qu'une valeur proche de 2 le rapproche d'un comportement gamma (sensible au coût moyen). Nous avons retenu $p = 1.5$, valeur couramment utilisée en tarification non-vie car elle équilibre les deux composantes.

Hyperparamètre	Valeur
objective	tweedie
tweedie_variance_power	1.5
learning_rate	0.005
num_leaves	10
min_data_in_leaf	500
feature_fraction	0.4
lambda_l2	5
num_boost_round	3000 (avec early stopping à 100 rounds)

Les choix de régularisation suivent une logique similaire à celle du modèle fréquence : **num_leaves** et **min_data_in_leaf** sont maintenus à des valeurs modérées pour éviter le surapprentissage sur les rares sinistres coûteux, qui domineraient autrement la fonction de perte. Le **feature_fraction** est légèrement relevé par rapport au modèle Poisson afin de donner au modèle la capacité de capturer à la fois les facteurs de fréquence et de sévérité au sein d'un même arbre.

La reconstruction de la charge finale est directe car contrairement aux deux modèles, aucune multiplication de composantes n'est nécessaire. Il suffit de multiplier la prédiction brute du modèle par l'**ANNEE_ASSURANCE** pour tenir compte de l'exposition :

$$\hat{\text{CHARGE}} = \hat{Y}_{\text{Tweedie}} \times \text{ANNEE_ASSURANCE}$$

Optimisation des hyperparamètres avec Optuna

Afin de chercher une configuration plus fine que celle définie manuellement, nous avons exploré l'utilisation d'Optuna [7], un framework d'optimisation automatique d'hyperparamètres basé sur un algorithme d'échantillonnage bayésien (*Tree-structured Parzen Estimator*, TPE). Le principe consiste à définir un espace de recherche pour chaque hyperparamètre, puis à lancer un grand nombre d'essais (*trials*) : à chaque essai, Optuna propose une combinaison de valeurs, entraîne le modèle correspondant et évalue sa

performance sur le jeu de validation, afin de converger progressivement vers les hyperparamètres optimaux.

En pratique, cette approche se serait révélée très lourde à exécuter dans notre contexte. Avec un jeu d'entraînement de plus de 380 000 lignes et 374 variables, chaque trial nécessite plusieurs minutes de calcul. La durée totale d'une étude Optuna suffisamment riche (50 à 100 trials) se chiffre en heures, ce qui a fortement limité notre capacité à itérer. Même en réduisant l'espace de recherche, les résultats obtenus en fin d'optimisation n'auraient pas permis de dépasser les performances du modèle deux-étapes.

Résultats et analyse

Le modèle Tweedie aboutit à un score comparable au pipeline Poisson+Gamma, sans amélioration significative sur la RMSE finale. Ce résultat, en apparence décevant, est en réalité cohérent avec la structure du problème : la RMSE étant très sensible aux valeurs extrêmes, c'est la qualité de prédiction sur les rares sinistres à coût élevé qui discrimine les modèles, et non la sophistication de l'architecture globale.

3.3 Réseau de neurones

Motivation et architecture générale

En complément des approches par gradient boosting, nous avons exploré l'utilisation d'un réseau de neurones dense pour modéliser directement la variable **CHARGE**. L'objectif est de tirer parti de la capacité des réseaux de neurones à capturer des interactions non-linéaires complexes entre les variables, là où LightGBM repose sur des partitions récursives de l'espace des features. De plus, c'est une modélisation plus intuitive pour nous car nous l'avons déjà étudié dans le cadre du cours *Introduction à l'Intelligence Artificielle* suivi au semestre précédent.

L'architecture retenue est un réseau séquentiel **Dense** à trois couches cachées, implémenté sous Keras [8]. Les entrées correspondent aux variables encodées de **X_train_enc**, normalisées à l'aide des statistiques du jeu d'entraînement. La couche de sortie produit une valeur scalaire avec une activation linéaire ou Softplus pour garantir la cohérence des prédictions.

Difficultés de modélisation et pistes explorées

La mise au point du réseau a nécessité plusieurs itérations importantes, chacune révélant une limite spécifique à la structure de nos données.

La première difficulté est l'effondrement vers zéro : un réseau entraîné naïvement avec une perte MSE sur les charges brutes converge systématiquement vers la prédiction constante $\hat{Y} = 0$. Ce comportement s'explique par la structure fortement gonflée en zéros de la variable **CHARGE** : minimiser l'erreur quadratique moyenne sur un jeu où plus de 99% des observations sont nulles revient à privilégier massivement la prédiction nulle, qui est mathématiquement optimale en l'absence de pondération.

Pour corriger cela, nous avons introduit des poids d'observation (**sample_weight**), pénalisant plus fortement les erreurs sur les contrats sinistrés. Si cette approche a permis au modèle de sortir du minimum trivial, les prédictions restaient très faibles (moyenne à 0,05 €, maximum à 0,66 €), en raison du biais d'ajustement introduit par le passage au logarithme.

Nous avons ensuite implémenté une fonction de perte Tweedie personnalisée ($p = 1,5$) appliquée directement sur les charges brutes, avec une activation **softplus** en sortie. Le modèle a alors produit des prédictions de l'ordre de grandeur attendu (moyenne à 552,54 €), mais avec une plage de variation extrêmement réduite (entre 136,87 € et 970,54 €), symptôme d'une explosion des gradients sur les montants bruts écrasant toute discrimination entre contrats.

Solution retenue : perte Tweedie avec log-link

La solution la plus efficace consiste à utiliser une fonction de perte Tweedie avec un lien logarithmique (*Log-Link*). Le réseau prédit un signal linéaire stable (le logarithme de la charge), tandis que la perte Tweedie est calculée sur l'exponentielle de ce signal, c'est-à-dire directement ramenée en euros. Un biais initial est injecté dans la couche de sortie pour initialiser les prédictions au niveau de la moyenne empirique, ce qui accélère fortement la convergence.

Ce paramétrage a produit un comportement actuariellement cohérent : les prédictions s'étalent entre 1,19 € et 800,78 € pour une moyenne à 70,00 €, avec une bonne discrimination entre profils à risque faible et élevé. Des signes de surapprentissage sont cependant apparus dès les premières époques, ce qui

a motivé l'introduction d'une régularisation L2 et la réduction de la taille du réseau ($64 \rightarrow 32 \rightarrow 16$ neurones par couche).

Résultats et combinaison des modèles

Afin de tirer parti des forces complémentaires des deux approches, nous avons fusionné les prédictions du réseau de neurones et du modèle LightGBM selon un ratio de 75% / 25%, conformément à la pratique usuelle des compétitions de *data science*. Le tableau suivant résume l'évolution des prédictions au fil des étapes :

Modèle	Moyenne	Min	Max	Diagnostic
Réseau initial (MSE)	0,00 €	0,00 €	0,00 €	Effondrement total vers zéro
Réseau (Tweedie brut)	552,54 €	136,87 €	970,54 €	Plage écrasée, gradients instables
Réseau (Tweedie log-link)	70,00 €	1,19 €	800,78 €	Bon comportement, surapprentissage précoce
Réseau optimisé (seul)	20,12 €	0,15 €	125,36 €	Ultra-régularisé, conservateur
LightGBM (seul)	131,48 €	0,10 €	3 386,94 €	Performant, détecte les gros sinistres
Fusion finale (75/25)	103,64 €	1,27 €	2 547,47 €	Meilleur équilibre risque/performance

La fusion conserve la capacité du LightGBM à détecter les sinistres extrêmes (maximum à 2 547,47 €) tout en bénéficiant de l'effet régularisant du réseau sur les prédictions intermédiaires. Le score obtenu sur la plateforme Challenge Data reste autour de 5 600, confirmant que le goulot d'étranglement réside dans la détection des rares sinistres à coût très élevé plutôt que dans l'architecture de modélisation globale.

4 Augmentation des données par réseau génératif

4.1 Introduction aux CTGAN

Face au déséquilibre de la quantité réelle de sinistre sur notre dataset (seulement 2 352 sinistres pour 383 610 contrats au total), nous avons décidé d'explorer une approche de génération de données synthétique par *Generative Adversarial Network* (GAN) [9].

Un GAN repose sur deux réseaux de neurones "adverses" : un générateur qui produit de fausses données en tentant de les rendre indiscernables des données réelles, et un discriminateur qui tente justement de les distinguer. Les deux s'améliorent mutuellement au fil de l'entraînement, jusqu'à ce que le générateur produise des données statistiquement réalistes.

Cependant, un GAN classique ne peut pas être appliqué directement à des données tabulaires comme les nôtres pour deux raisons. D'abord, nos 280 variables catégorielles prennent des valeurs discrètes non ordonnées, qu'un GAN ne peut pas reproduire directement. De plus, la distribution de **CHARGE** est fortement déséquilibrée : la quasi-totalité des contrats présente une charge nulle, tandis qu'une minorité affiche des valeurs très élevées. Une structure hétérogène qu'un GAN classique ne parvient pas à reproduire fidèlement.

Le *Conditional Tabular GAN* (CTGAN) résout ces deux problèmes par deux mécanismes spécifiques. Le *Variational Gaussian Mixture* (VGM) modélise chaque variable continue comme une combinaison de plusieurs gaussiennes, permettant de reproduire fidèlement des distributions complexes à queue lourde. L'échantillonnage conditionnel oblige le générateur à produire des données de chaque catégorie de manière équilibrée, quelle que soit sa fréquence dans le dataset réel. Sans ce mécanisme, le CTGAN apprendrait quasi-exclusivement la distribution des contrats non-sinistrés.

4.2 Entraînement et Résultats des Modèles sur ces Données

Le CTGAN est entraîné exclusivement sur les 2 352 contrats sinistrés, jamais sur l'ensemble du dataset. Ce choix évite tout *data leakage* : les données synthétiques générées n'introduisent aucune information provenant du jeu de test, mais enrichissent uniquement la connaissance statistique des sinistres déjà disponible en entraînement.

Avant l'entraînement, les valeurs manquantes sont remplacées par une valeur par défaut (**INCONNU** pour les catégorielles, 0 pour les numériques), car le CTGAN ne gère pas les **NaN** directement. Le modèle est alors entraîné sur 50 *epochs* avec un batch de taille 500, ce qui représente un bon compromis entre

qualité des données générées et temps de calcul.

Avant d'utiliser les données synthétiques pour réentraîner nos modèles, nous vérifions que le CTGAN a correctement appris la distribution statistique des sinistres réels. Cette validation se fait par comparaison des distributions réelles et synthétiques sur trois types de variables : le coût moyen **CM** (en échelle logarithmique pour mieux visualiser la queue), une variable numérique de surface, et les fréquences relatives de la variable catégorielle **ACTIVIT2**.

Un CTGAN bien entraîné doit reproduire la forme générale de ces distributions sans se contenter de copier les valeurs exactes des observations réelles, ce qui signalerait un phénomène de mémorisation (*overfitting* du générateur).

LightGBM Tweedie + GAN : score 5 600

Maintenant que nous avons ces données synthétiques, nous les injectons dans un modèle LightGBM avec objectif Tweedie (variance power = 1,2). Ce type de modèle est particulièrement adapté à notre problème : la loi de Tweedie généralise à la fois la loi de Poisson et la loi Gamma, ce qui lui permet de modéliser directement une charge agrégée comportant une masse de zéros et une queue lourde, sans décomposer explicitement fréquence et coût moyen.

Les données synthétiques (concaténées aux données réelles à l'entraînement) permettent d'enrichir la représentation des sinistres rares et d'améliorer la robustesse du modèle face à ce déséquilibre. Cette approche produit un score de 5 600 sur le leaderboard, légèrement meilleur que les deux modèles séparés Poisson $\times$ Gamma de quelques centièmes.

Réseau de neurones : résultats décevants

Puis, nous les avons injectées dans le réseau de neurones développé précédemment (architecture RELU + BatchNormalization + Dropout, loss Tweedie log-link), en espérant que l'enrichissement du jeu d'entraînement permette au réseau de mieux capturer les sinistres rares. Les prédictions restent cependant trop resserrées (1,84 € à 567 €) et la fusion 75/25 avec LightGBM ne parvient pas à améliorer le score : le réseau n'apporte pas suffisamment d'information complémentaire.

Nous avons alors tenté une architecture plus simple (Dense 64 $\rightarrow$ 32 $\rightarrow$ 1, activation ReLU, loss MSE) pour voir si une approche plus directe donnerait de meilleurs résultats. Sans succès : le modèle converge vers $\hat{Y} \approx 0$ sur l'ensemble des observations, car minimiser l'erreur quadratique sur un jeu à 99 % de zéros revient à privilégier la prédiction nulle.

Enfin, nous avons testé une décomposition en deux modèles séquentiels : un classifieur prédisant la probabilité de sinistre (avec pondération de classes), et un régresseur entraîné sur le logarithme de la charge pour les seuls contrats sinistrés, combinés par produit. Le maximum prédit atteint 16 560,78 €, ce qui montre une meilleure détection des sinistres extrêmes, mais la moyenne reste très faible (0,57 €) : le classifieur sous-estime fortement la probabilité de sinistre, ce qui écrase le produit final.

Ces échecs sont cohérents avec la littérature [10] : sur des données tabulaires très déséquilibrées avec de nombreuses variables catégorielles et peu d'exemples positifs, les réseaux de neurones denses souffrent de l'écrasement des gradients par la masse de zéros et peinent à s'adapter à la géométrie non euclidienne des variables discrètes. LightGBM, en revanche, gère nativement ces deux caractéristiques via ses arbres de décision et son encodage catégoriel intégré.

LightGBM Tweedie + K-Fold + GAN : score 5 599

Pour tirer pleinement parti des données synthétiques et réduire la variance de l'estimation, nous combinons l'augmentation CTGAN avec une validation croisée K-Fold à 5 plis.

La validation croisée K-Fold consiste à partitionner le jeu d'entraînement en K sous-ensembles (ici $K = 5$). À chaque itération, $K - 1$ plis servent à entraîner le modèle et le pli restant sert de validation. On entraîne ainsi K modèles distincts sur des sous-ensembles différents, puis on moyenne leurs prédictions sur le jeu de test. Cette procédure présente deux avantages : elle utilise la totalité des données en entraînement

sur au moins un fold, et elle réduit significativement la variance des prédictions finales par rapport à un simple découpage train/validation. La RMSE out-of-fold (OOF), qui est calculée en agrégeant les prédictions de validation de chaque fold, fournit par ailleurs une estimation fiable de la performance en généralisation, sans avoir recours au jeu de test.

Dans notre pipeline augmenté, les données synthétiques générées par le CTGAN sont concaténées aux données réelles d'entraînement à chaque fold, après que les indices de validation ont été fixés. Cela garantit que les données synthétiques n'influencent jamais l'évaluation OOF, préservant l'intégrité de l'estimation.

Les résultats par fold sur les données d'entraînement sont les suivants :

Fold	Meilleure itération	RMSE locale
1	397	7 749,37 €
2	423	6 305,05 €
3	415	6 786,76 €
4	198	6 545,01 €
5	318	6 405,51 €
Global OOF		6 778,41 €

La moyenne des prédictions test sur les 5 folds produit un score final de 5 599 sur le leaderboard, soit le meilleur résultat obtenu. Une amélioration d'un point par rapport au modèle Tweedie sans K-Fold, confirmant le bénéfice de l'ensembling dans ce contexte à données déséquilibrées.

5 Équité du Modèle : Disparate Impact

5.1 Définition et cadre théorique

L'analyse d'équité d'un modèle prédictif vise à détecter si certains groupes d'individus sont systématiquement défavorisés par les prédictions, indépendamment de leur risque réel. Le *disparate impact* (DI) est l'une des métriques d'équité les plus utilisées en apprentissage automatique. Introduite dans le contexte légal américain [11], elle mesure le rapport entre les taux de décisions favorables entre un groupe non-privilegié et un groupe de référence.

Formalisation

Soit A une variable sensible prenant des valeurs dans un ensemble fini de groupes $\mathcal{G} = \{g_0, g_1, \dots, g_K\}$, où g_0 désigne le groupe de référence (généralement le groupe majoritaire). Soit $\hat{Y}$ la variable aléatoire représentant la prédiction du modèle et τ un seuil fixé. On dit qu'une prédiction est *favorable* si $\hat{Y} \leq \tau$ (l'assuré se voit attribuer une prime faible). Le disparate impact du groupe g_k par rapport au groupe de référence g_0 est alors défini par :

$$\text{DI}(g_k) = \frac{P(\hat{Y} \leq \tau \mid A = g_k)}{P(\hat{Y} \leq \tau \mid A = g_0)}$$

Un modèle est considéré équitable vis-à-vis du groupe g_k si $\text{DI}(g_k) \geq 0.8$, ce qui correspond à la règle des 80 % couramment retenue. En pratique, on estime ces probabilités empiriquement sur un jeu de validation de taille n . Pour un groupe g contenant n_g observations, on pose :

$$\hat{P}(\hat{Y} \leq \tau \mid A = g) = \frac{1}{n_g} \sum_{i: A_i = g} \mathbb{1}[\hat{Y}_i \leq \tau]$$

d'où l'estimateur empirique du disparate impact :

$$\widehat{\text{DI}}(g_k) = \frac{\frac{1}{n_{g_k}} \sum_{i: A_i = g_k} \mathbb{1}[\hat{Y}_i \leq \tau]}{\frac{1}{n_{g_0}} \sum_{i: A_i = g_0} \mathbb{1}[\hat{Y}_i \leq \tau]}$$

Propriété de consistance de l'estimateur

Sous l'hypothèse que les observations sont indépendantes et identiquement distribuées au sein de chaque groupe, la loi des grands nombres garantit la convergence presque sûre de $\widehat{\text{DI}}(g_k)$ vers $\text{DI}(g_k)$ lorsque $\min(n_{g_k}, n_{g_0}) \rightarrow +\infty$. En particulier, par le théorème de Slutsky, le ratio de deux estimateurs convergents est lui-même convergent, à condition que le dénominateur soit borné inférieurement loin de zéro :

$$\widehat{\text{DI}}(g_k) \xrightarrow{\text{p.s.}} \text{DI}(g_k) \quad \text{si } P(\hat{Y} \leq \tau \mid A = g_0) > 0$$

Cette propriété justifie l'utilisation de l'estimateur empirique mais souligne également une limite importante : pour les groupes de très petite taille (n_{g_k} faible), la variance de l'estimateur est élevée et l'interprétation du $\widehat{\text{DI}}$ doit rester prudente.

Lien avec le rapport de vraisemblance

On peut relier le disparate impact à un rapport de vraisemblance, ce qui permet d'en donner une interprétation probabiliste plus profonde. Notons $p_k = P(\hat{Y} \leq \tau \mid A = g_k)$. Par la règle de Bayes :

$$P(A = g_k \mid \hat{Y} \leq \tau) = \frac{p_k \cdot P(A = g_k)}{P(\hat{Y} \leq \tau)}$$

Le rapport de vraisemblance entre le groupe g_k et le groupe g_0 conditionnellement à une prédiction favorable vaut alors :

$$\frac{P(A = g_k \mid \hat{Y} \leq \tau)}{P(A = g_0 \mid \hat{Y} \leq \tau)} = \frac{p_k}{p_0} \cdot \frac{P(A = g_k)}{P(A = g_0)} = \text{DI}(g_k) \cdot \frac{P(A = g_k)}{P(A = g_0)}$$

Ainsi, un $\text{DI}(g_k) = 1$ signifie que l'appartenance au groupe g_k n'apporte aucune information sur le fait d'obtenir une prédiction favorable au-delà de la proportion de ce groupe dans la population : le modèle est alors dit *indépendant* de la variable A au sens de la parité démographique (*demographic parity*).

5.2 Adaptation au contexte de régression

Notre variable cible **CHARGE** est une grandeur continue, ce qui nécessite d'adapter la définition classique du disparate impact, formulée pour des sorties binaires. Nous binarisons les prédictions à l'aide du seuil τ défini comme la médiane des charges prédites sur le jeu de validation : une prime $\hat{Y}_i \leq \tau$ est qualifiée de *favorable* (l'assuré est moins pénalisé financièrement). Ce choix de la médiane présente l'avantage de garantir par construction que $P(\hat{Y} \leq \tau) = 0.5$, ce qui évite les déséquilibres artificiels dans le taux de base.

5.3 Choix de la variable sensible

Spécificité du contexte assurantiel agricole

Dans un contexte assurantiel classique (assurance automobile, emprunteur, santé), les variables sensibles typiques sont le sexe, l'âge ou l'origine, qui sont soit légalement protégées soit indépendantes du risque par nature. Notre jeu de données ne contient pas de telles variables : toutes les caractéristiques disponibles (type d'activité agricole, superficie, zone géographique, données météorologiques) sont a priori corrélées au risque incendie réel.

Cette remarque est fondamentale car dans notre cas, un disparate impact $\text{DI}(g_k) < 0.8$ n'est pas nécessairement le signe d'une discrimination injuste du modèle [12]. Il peut tout à fait refléter une hétérogénéité de risque *objective* entre les groupes. L'analyse du DI joue ici davantage le rôle d'un indicateur de robustesse car un groupe fortement sous- ou sur-estimé par rapport à sa fréquence de prédiction favorable signale que le modèle traite ce groupe différemment, ce qui peut révéler soit un biais de modélisation, soit une absence de données suffisantes pour ce groupe.

Variable retenue : ACTIVIT2

Nous avons retenu la variable **ACTIVIT2**, qui encode le type d'activité agricole du contrat, comme attribut sensible principal. Le groupe de référence g_0 est **ACT1**, le groupe le plus représenté dans le jeu de validation, conformément à la pratique standard. Le seuil retenu est la médiane des charges prédites, soit $\tau = 115,72$ €, pour un taux favorable de référence de $\hat{p}_0 = 0,487$.

5.4 Résultats

Groupe (ACTIVIT2)	Taille	Taux favorable	DI
ACT1 : groupe référence	-	0,487	1,000
ACT2	2 875	0,826	1,695
ACT3	1 016	0,552	1,133
ACT4	72	0,278	0,570
ACT5	10 854	0,471	0,966
ACT6	201	0,826	1,694
ACT7	427	0,468	0,961
ACT8	1 098	0,369	0,757
ACT9	903	0,692	1,420

TABLE 1 – Disparate Impact par groupe d'activité agricole (**ACTIVIT2**) sur le jeu de validation. Les valeurs en gras sont inférieures au seuil critique de 0,8.

5.5 Interprétation

Sur les huit groupes évalués, deux présentent un disparate impact inférieur au seuil critique de 0,8 : **ACT4** ($\widehat{DI} = 0,570$) et **ACT8** ($\widehat{DI} = 0,757$). À l'inverse, **ACT2** et **ACT6** affichent des valeurs supérieures à 1,6, indiquant qu'ils reçoivent des prédictions favorables bien plus souvent que le groupe de référence.

ACT4 ne compte que 72 observations dans le jeu de validation. La variance de l'estimateur $\widehat{DI}$ est alors très élevée : une variation de quelques prédictions suffit à faire basculer le ratio. Ce résultat ne peut donc pas être interprété comme un signal robuste de biais, il illustre précisément la limite de consistance de l'estimateur, à savoir que $\widehat{DI}$ n'est fiable que lorsque n_{g_k} est suffisamment grand.

ACT8, avec 1 098 observations, offre un résultat statistiquement plus solide. Un DI de 0,757 signifie que les contrats de ce groupe ont environ 24 % moins de chances que le groupe de référence d'obtenir une prime prédite inférieure à la médiane. On peut émettre l'hypothèse que cette catégorie correspond à des exploitations à fort volume de récolte stockée (céréales, foin), qui présentent objectivement un risque incendie plus élevé. Le modèle leur attribue alors structurellement des charges prédites plus importantes ce qui est actuariellement cohérent, mais se traduit mécaniquement par un DI dégradé.

Ces observations confirment la remarque métier soulevée précédemment : dans notre contexte, l'absence de variables réellement indépendantes du risque rend toute conclusion sur la *discrimination* du modèle impossible au sens légal. Le disparate impact fonctionne ici comme un indicateur de cohérence interne : il révèle que le modèle différencie effectivement les groupes à risque hétérogène, ce qui est précisément son rôle en tarification non-vie. Une valeur de DI éloignée de 1 ne signale donc pas un défaut du modèle, mais reflète la réalité du risque sous-jacent porté par chaque type d'activité agricole.

6 Conclusion

Ce travail de recherche avait pour objectif de développer un modèle performant pour la prédiction de la prime pure liée au risque incendie dans le cadre du challenge AssurPrime. À travers une exploration méthodique de plusieurs approches, nous avons pu tirer des enseignements à la fois techniques et métiers.

Notre première approche, fondée sur la décomposition actuarielle classique fréquence-coût via deux modèles LightGBM distincts (Poisson et Gamma), s'est révélée immédiatement compétitive avec un score de 5 600 sur la plateforme, à seulement 6 points du premier du classement. Le modèle Tweedie unifié, bien que théoriquement mieux car il évite la propagation d'erreurs entre les deux étapes, n'a pas permis

de dépasser ce résultat, même après optimisation automatique des hyperparamètres via Optuna. Quant aux réseaux de neurones denses, ils se sont heurtés aux difficultés structurelles bien documentées sur les données tabulaires fortement déséquilibrées : effondrement vers zéro, instabilité des gradients, et capacité limitée à gérer les variables catégorielles nombreuses. La fusion avec LightGBM n'a pas suffi à combler cet écart. L'approche la plus prometteuse s'est avérée être la combinaison de l'augmentation de données synthétiques par CTGAN et de la validation croisée K-Fold, qui a produit notre meilleur score de 5 599. Si l'amélioration reste marginale en valeur absolue, elle confirme que le principal goulot d'étranglement de ce problème réside dans la détection des rares sinistres à coût très élevé, qui dominent la RMSE. Enrichir statistiquement cette minorité critique est donc une piste pertinente, même si les gains sont limités par la faible taille de l'échantillon réel de sinistres. Enfin, l'analyse du disparate impact a mis en lumière une spécificité fondamentale du contexte assurantiel agricole : en l'absence de variables réellement indépendantes du risque, le DI ne peut pas être interprété comme un indicateur de discrimination injuste au sens légal, mais constitue plutôt un outil de cohérence interne. Les écarts observés pour certains groupes d'activité, notamment ACT8, semblent refléter des différences de risque objectif plutôt qu'un biais de modélisation.

En perspective, plusieurs pistes restent à explorer : un feature engineering plus poussé ciblant spécifiquement les sinistres extrêmes, l'utilisation de modèles à deux parties plus sophistiqués (hurdle models), ou encore des architectures de type tabular transformers mieux adaptées aux données mixtes à grande dimension.

Références

- [1] ENS Paris. *Challenge Data – Challenge no. 161*. Plateforme Challenge Data, École Normale Supérieure. <https://challengedata.ens.fr/participants/challenges/161/>
- [2] https://github.com/helenacros/STAGE_MIDL.git
- [3] OHLSSON, Esbjörn, AND JOHANSSON, Björn. *Non-Life Insurance Pricing with Generalized Linear Models*. Berlin, Heidelberg : Springer Science & Business Media, 2010.
- [4] Microsoft Corporation. *LightGBM Documentation*, version 4.6.0. Consulté en 2025. <https://lightgbm.readthedocs.io/en/stable/>
- [5] JORGENSEN, Bent, AND DE SOUZA, M. Carmen P. Fitting Tweedie’s Compound Poisson Model to Insurance Claims Data. *Scandinavian Actuarial Journal*, vol. 1994, no. 1, 1994, pp. 69-93.
- [6] ZERROUK, Leila. *Méthodes d’approximation de la densité Tweedie et applications en actuariat*. Mémoire de maîtrise en mathématiques. Montréal : Université du Québec à Montréal, mai 2017.
- [7] AKIBA, Takuya, SANO, Shotaro, YANASE, Toshihiko, OHTA, Takeru, AND KOYAMA, Masanori. Optuna : A Next-generation Hyperparameter Optimization Framework. *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, août 2019. <https://doi.org/10.1145/3292500.3330701>
- [8] Keras Team. *Keras : Deep Learning for Humans*. Consulté en 2025. <https://keras.io>
- [9] KIM, Dong-Keon. CTGAN : How GANs Finally Learned to Handle Tabular Data. *Medium*, 31 mars 2025.
- [10] LI, Zhong, HUANG, Qi, YANG, Lincen, SHI, Jiayang, YANG, Zhao, VAN STEIN, Niki, BÄCK, Thomas, AND VAN LEEUWEN, Matthijs. Diffusion Models for Tabular Data : Challenges, Current Progress, and Future Directions. *arXiv preprint arXiv :2502.17119*, février 2025. Dépôt GitHub : <https://github.com/Diffusion-Model-Leiden/awesome-diffusion-models-for-tabular-data>
- [11] IBM Corporation. *Disparate Impact Evaluation Metric*. IBM Watson Studio and Knowledge Catalog Documentation. Consulté en 2025. <https://www.ibm.com/docs/en/ws-and-kc?topic=metrics-disparate-impact>
- [12] The leadership conference on civil and human rights. Disparate Impact as Uniquely Relevant in the Age of AI. *When Machines Discriminate : The Critical Role of Disparate Impact in AI Accountability*, janvier 2026. <https://civilrights.org/disparate-impact-age-of-ai/>